

Projet Optical Flow – UM4MA266

Optimisation et science des données

UGWONALI Nathan
Master 1 Mathématiques et Applications

Année 2025–2026

Résumé

Ce rapport présente les grands principes, le processus d'implémentation ainsi que les résultats de l'étude de quelques algorithmes liés à l'optical flow.

Table des matières

1 Introduction **1**

2 Modélisation mathématique **2**
2.1 Equation de conservation 2
2.2 Condition de lissage 2
2.3 Minimisation 2

3 Implémentation numérique **3**
3.1 Approximations 3
3.2 Implémentation orientée objet 3
3.3 Méthodes d'optimisation 3
3.3.1 Méthode de Gauss-Seidel 3
3.3.2 Méthode de descente de gradient à pas fixe 4

4 Implémentation de la méthode de Lucas-Kanade **5**
4.1 Idées de la méthode 5
4.2 Implémentation numérique 5

5 Pénalisation en norme 1 **5**
5.1 Problématique liée à la non-dérivabilité 5
5.2 Résolution par les approches proximales 6
5.3 L'opérateur proximal : une généralisation de la projection 6
5.4 Lien théorique entre l'algorithme de Chambolle et l'opérateur proximal 6
5.4.1 Dualité de Fenchel-Legendre 6
5.4.2 La décomposition de Moreau et le problème dual 7
5.5 Mise en oeuvre algorithmique 7

6 Résultats **9**
6.1 Comparaison entre les deux méthodes d'optimisation en norme L2 9
6.2 Influence du paramètre de lissage 9
6.3 Analyse de la méthode de Lucas-Kanade 11
6.4 Analyse des résultats pour la méthode TV-L2 et comparaison avec la régularisation L2 13
6.4.1 Comparaison visuelle : Horn-Schunck vs TV-L2 13
6.4.2 Analyse des performances temporelles 14

7 Conclusion **16**

1 Introduction

L'optical flow se définit comme la mesure du mouvement relatif entre deux images. Ce concept est particulièrement bien adapté à la vidéo dans la mesure où ces dernières se décomposent en plusieurs images successives (30 à 60 images par secondes en général). Ainsi, en

supposant que chaque frame est relativement proche de la précédente, on peut approximer le champ des vitesses associé au mouvement décrit par les images. On trouvera de nombreuses application dans le domaine de la vision par ordinateur.

2 Modélisation mathématique

2.1 Equation de conservation

On se place dans le formalisme d'Euler. On considère l'éclairement en un pixel situé au coordonnées (x, y) et à l'instant t, noté $E(x, y, t)$. L'hypothèse central est la conservation de cet eclairement au cours du temps. Ceci ce traduit par l'équation de conservation :

$$\frac{DE}{Dt} = 0 \tag{1}$$

Ceci devient en développant :

$$\frac{\partial E}{\partial x}\frac{dx}{dt} + \frac{\partial E}{\partial y}\frac{dy}{dt} + \frac{\partial E}{\partial t} = 0 \tag{2}$$

En notant $E_i = \frac{\partial E}{\partial i}, i \in \{x, y, t\}$ et $u = \frac{dx}{dt}, v = \frac{dy}{dt}$, on obtient la forme compact suivante :

$$E_x u + E_y v + E_t = 0 \tag{3}$$

L'objectif est alors de trouver u et v, sachant (E_x, E_y, E_t) donné par la vidéo considérée.

2.2 Condition de lissage

Le problème posé tel que précédement est mal posé puisqu'il existe une infité de couple (u, v) verifiant l'équation de conservation. Il s'agit alors de considérer une nouvelle équation afin de compléter le problème. Une approche est donnée par Horn et Schunck [2] qui proposent de considérer une condition de lissage traduisant le fait que le champ des vitesses en un point est globalement similaire a ses voisins. On introduit alors l'erreur de lissage, que l'on va venir chercher à minimiser :

$$e_s = \|\nabla u\|^2 + \|\nabla v\|^2 = \left(\frac{\partial u}{\partial x}\right)^2 + \left(\frac{\partial u}{\partial y}\right)^2 + \left(\frac{\partial v}{\partial x}\right)^2 + \left(\frac{\partial v}{\partial y}\right)^2 \tag{4}$$

On obtient alors, en intégrant sur tous le domaine Ω, l'intégrale suivante, que l'on cherche à minimiser en (u, v) :

$$\mathcal{E}(u, v) = \iint_\Omega \left((E_x u + E_y v + E_t)^2 + \alpha^2 \left(\left(\frac{\partial u}{\partial x}\right)^2 + \left(\frac{\partial u}{\partial y}\right)^2 + \left(\frac{\partial v}{\partial x}\right)^2 + \left(\frac{\partial v}{\partial y}\right)^2 \right) \right) dxdy \tag{5}$$

Avec α un hyperparamètre qui arbitre entre effets globaux de lissage et effets locaux de variation de l'intensité lumineuse.

2.3 Minimisation

Afin de minimiser une intégrale, on trouvera en les équations d'Euler-Lagrange un outil puissant. Nous admettront bien volontier que ces dernières nous mènent au système d'équation suivant :

$$\begin{cases} E_x(E_x u + E_y v + E_t) - \alpha^2 \Delta u = 0 \\ E_y(E_x u + E_y v + E_t) - \alpha^2 \Delta v = 0 \end{cases} \tag{6}$$

Un tel système d'équation n'est pas solvable sans approximation intelligentes. C'est pourquoi on se propose de résoudre ce dernier par une méthode itérative telle que celles de Jacobi ou Gauss-Seidel. Pour ce faire, on commence par approximer le laplacien $\Delta f = \bar{f} - f$, ce qui donne :

$$\begin{cases} E_x(E_x u + E_y v + E_t) - \alpha^2(\bar{u} - u) = 0 \\ E_y(E_x u + E_y v + E_t) - \alpha^2(\bar{v} - v) = 0 \end{cases} \tag{7}$$

On réarrange les termes :

$$\begin{cases} u - \bar{u} = -E_x \frac{E_x u + E_y v + E_t}{\alpha^2} \\ v - \bar{v} = -E_y \frac{E_x u + E_y v + E_t}{\alpha^2} \end{cases} \tag{8}$$

3 Implémentation numérique

3.1 Approximations

Il s'agit dans un premier temps de récupérer le flux vidéo. L'idée étant de gérer les images deux-à-deux afin d'en extraire les variations d'intensité lumineuse par convolution. Toujours selon Horn et Schunck [2], une méthode consiste à approximer les variations pixels par pixels et frame par frame étant donné que l'on a pas d'idée a priori du facteur d'échelle ni des fps de la vidéo.

$$\begin{cases} E_x \approx \frac{1}{4}\Big[(E_{i,j+1,k} - E_{i,j,k}) + (E_{i+1,j+1,k} - E_{i+1,j,k}) \\ \qquad + (E_{i,j+1,k+1} - E_{i,j,k+1}) + (E_{i+1,j+1,k+1} - E_{i+1,j,k+1})\Big] \\ E_y \approx \frac{1}{4}\Big[(E_{i+1,j,k} - E_{i,j,k}) + (E_{i+1,j+1,k} - E_{i,j+1,k}) \\ \qquad + (E_{i+1,j,k+1} - E_{i,j,k+1}) + (E_{i+1,j+1,k+1} - E_{i,j+1,k+1})\Big] \\ E_t \approx \frac{1}{4}\Big[(E_{i,j,k+1} - E_{i,j,k}) + (E_{i+1,j,k+1} - E_{i+1,j,k}) \\ \qquad + (E_{i,j+1,k+1} - E_{i,j+1,k}) + (E_{i+1,j+1,k+1} - E_{i+1,j+1,k})\Big] \end{cases} \tag{9}$$

3.2 Implémentation orientée objet

Ainsi, on implémente une première classe VideoDataHandler qui permet d'une part d'extraire le flux d'images issu d'une vidéo donnée en donnant les images par paquets de deux. Cette dernière permet aussi de faire du prétraitement de l'image, à savoir la passer en monochrome et avec intensité normalisée à 1. A cela, on ajoute les classes GradIntensity et Velocity qui permettent le calcul respectivement, des champs liés à l'intensité pour une paire d'images fournies par le VideoHandler et des champs liés à la vitesse, notamment le Laplacien. Enfin, la classe Optimization est introduite pour encoder les différentes méthodes d'optimisations envisagées.

3.3 Méthodes d'optimisation

3.3.1 Méthode de Gauss-Seidel

Il s'agit ici de la méthode que Horn et Schunck [2] ont choisi d'implémenter de par son efficacité dans ce contexte. Le principe de la méthode est le suivant : face à un système d'équations linéaires vaste et creux (comme c'est le cas pour les pixels d'une image), les méthodes

de résolution directe par inversion de matrice sont beaucoup trop coûteuses en temps de calcul et en mémoire. La méthode de Gauss-Seidel propose une approche itérative. À partir d'une estimation initiale du champ de vitesses (généralement nulle), l'algorithme met à jour la valeur de chaque variable en utilisant les valeurs les plus récentes de ses voisines, jusqu'à atteindre un état d'équilibre.

Dans notre cas, nous cherchons à résoudre le système algébrique obtenu après discrétisation des équations d'Euler-Lagrange :

$$\begin{cases} (\alpha^2 + E_x^2)u + E_x E_y v = \alpha^2 \bar{u} - E_x E_t \\ E_x E_y u + (\alpha^2 + E_y^2)v = \alpha^2 \bar{v} - E_y E_t \end{cases} \tag{10}$$

Plutôt que de traiter ce système de manière globale, Horn et Schunck ont réécrit ces équations pour exprimer la vitesse d'un pixel en fonction des dérivées spatio-temporelles locales de l'image (E_x, E_y, E_t) et de la moyenne des vitesses de son voisinage spatio-temporel ($\bar{u}$, $\bar{v}$).

En isolant astucieusement le terme fractionnaire commun aux deux équations, on obtient le schéma itératif suivant. Soit k l'indice de l'itération courante, les nouvelles composantes du vecteur vitesse pour l'itération $k+1$ sont données par :

$$\begin{cases} u^{k+1} = \bar{u}^k - E_x \dfrac{E_x \bar{u}^k + E_y \bar{v}^k + E_t}{\alpha^2 + E_x^2 + E_y^2} \\ \\ v^{k+1} = \bar{v}^k - E_y \dfrac{E_x \bar{u}^k + E_y \bar{v}^k + E_t}{\alpha^2 + E_x^2 + E_y^2} \end{cases} \tag{11}$$

Cette formulation est particulièrement élégante car elle évite toute inversion matricielle. Chaque itération affine le champ de vitesses en propageant l'information des zones riches en gradients (les contours) vers les zones homogènes, grâce au calcul des moyennes locales $\bar{u}$ et $\bar{v}$ qui agissent comme un terme de diffusion.

Le processus itératif est répété jusqu'à ce que le système converge. En pratique, la condition d'arrêt est définie par un seuil de tolérance ϵ. L'algorithme s'interrompt lorsque la différence quadratique moyenne entre le champ de vitesses de l'itération k et celui de l'itération $k+1$ devient strictement inférieure à ce seuil, ou lorsqu'un nombre maximum d'itérations est atteint.

3.3.2 Méthode de descente de gradient à pas fixe

Afin d'établir un point de comparaison algorithmique avec l'approche de Horn et Schunck, le système a également été résolu en utilisant une méthode d'optimisation universelle du premier ordre : la descente de gradient à pas fixe.

On ne rappelera pas le principe très connue de la méthode.

Soit λ le pas d'apprentissage (ou *learning rate*), fixé empiriquement et maintenu constant tout au long de l'optimisation. La règle de mise à jour simultanée des champs de vitesses à l'itération $k+1$ est donnée par :

$$\begin{cases} u^{k+1} = u^k - \lambda \nabla_u E(u^k, v^k) \\ v^{k+1} = v^k - \lambda \nabla_v E(u^k, v^k) \end{cases} \tag{12}$$

Contrairement à la méthode de Gauss-Seidel qui exploite la structure mathématique spécifique du Laplacien pour garantir une convergence stable, la descente de gradient classique est extrêmement sensible au choix de l'hyperparamètre λ.

Si le pas λ est choisi trop grand, l'algorithme oscille et finit par diverger, ce qui se traduit par une explosion des valeurs des vecteurs vitesses. S'il est choisi trop petit, la descente vers

le minimum global est assurée, mais le nombre d'itérations requis pour atteindre le seuil de tolérance ϵ devient prohibitif, rendant cette méthode considérablement plus lente que l'approche proposée initialement par Horn et Schunck.

4 Implémentation de la méthode de Lucas-Kanade

4.1 Idées de la méthode

La méthode de Lucas et Kanade [3] se base sur les mêmes hypothèses que présentées précedemment avec la méthode de Horn et Schunck [2]. La différence dans la méthode réside dans la résolution des équations du flux optique. En effet, Lucas et Kanade optent pour une résolution à l'aide des moindres carrés en considérant un ensemble de pixel autour d'un pixel bien choisi. Ces dits pixels bien choisis sont en général des coins des objets en mouvement. Ces coins sont particulièrement pertinent dans la mesure où le mouvement de ces derniers évitent toutes ambiguités, on parle d'"aperture problem".

4.2 Implémentation numérique

On utilisera la code fourni par le sujet, qui nous renvoie vers OpenCV et leur implémentation de la méthode de Lucas et Kanade. L'algorithme commence par extraire la première image puis par détecter les coins grâce à la méthode goodFeaturesToTrack. La méthode calcOpticalFlowPyrLK permet de réaliser l'optimisation dans la boucle. L'algorithme renvoie alors les trajectoires des coins qui ont été detectés.

5 Pénalisation en norme 1

Dans cette section, on se propose de traiter le cas où la fonction de coût globale de l'énergie à minimiser prend la forme suivante :

$$E(u,v) = \iint \left(I_x u + I_y v + I_t\right)^2 dxdy + \alpha \iint \left(|\nabla u| + |\nabla v|\right) dxdy \tag{13}$$

C'est-à-dire que le terme de régularisation n'est plus exprimé en norme L2 mais en norme L1, ce qui complique les calculs d'optimisation.

5.1 Problématique liée à la non-dérivabilité

Le passage d'une pénalisation quadratique (L^2) à une pénalisation en norme L^1 permet de préserver les discontinuités du champ de vitesses et d'éviter l'effet de lissage aux frontières des objets en mouvement. Cependant, cette modification soulève un défi d'optimisation majeur : la fonction valeur absolue n'est pas dérivable en zéro.

Il se trouve que si l'on tente de minimiser cette énergie par l'approche variationnelle classique (équations d'Euler-Lagrange) utilisée pour le modèle de Horn et Schunck, on aboutit à un terme de diffusion de la forme $\operatorname{div}\left(\frac{\nabla u}{|\nabla u|}\right)$. Ce terme devient singulier précisément dans les zones où le champ de mouvement est homogène (là où $|\nabla u| \to 0$), entraînant une division par zéro. Les algorithmes d'optimisation basés sur le gradient standard ou les solveurs itératifs lisses comme Gauss-Seidel deviennent alors mathématiquement inapplicables.

5.2 Résolution par les approches proximales

Pour contourner ce verrou théorique inhérent à l'optimisation non lisse, il est nécessaire de s'appuyer sur des approches dites *proximales*. Ces méthodes ne requièrent pas la stricte différentiabilité de la fonction objectif. Elles remplacent les étapes de descente de gradient classiques (impossibles sur le terme de régularisation) par l'évaluation d'un opérateur mathématique appelé *opérateur proximal*.

5.3 L'opérateur proximal : une généralisation de la projection

Pour surmonter la non-dérivabilité de la norme L^1, l'analyse convexe introduit un outil fondamental : l'opérateur proximal. Ce concept s'appréhende le plus intuitivement comme une généralisation de l'opérateur de projection classique.

Rappelons que la projection orthogonale d'un point v sur un ensemble convexe fermé C consiste à trouver le point $x \in C$ minimisant la distance géométrique avec v :

$$\Pi_C(v) = \arg\min_{x \in C} \frac{1}{2}\|x - v\|_2^2 \tag{14}$$

Cette formulation contrainte peut se réécrire sous la forme d'un problème d'optimisation non contraint en utilisant la fonction indicatrice ι_C de l'ensemble C (définie par 0 sur C et $+\infty$ ailleurs) :

$$\Pi_C(v) = \arg\min_{x} \left(\iota_C(x) + \frac{1}{2}\|x - v\|_2^2 \right) \tag{15}$$

L'opérateur proximal étend directement cette idée. Il consiste à remplacer la fonction indicatrice par une fonction convexe fermée quelconque f, pondérée par un paramètre d'échelle $\lambda > 0$:

$$\text{prox}_{\lambda f}(v) = \arg\min_{x} \left(f(x) + \frac{1}{2\lambda}\|x - v\|_2^2 \right) \tag{16}$$

L'opérateur proximal agit ainsi comme un mécanisme de compromis : il cherche un point x qui minimise la valeur de la fonction f, tout en pénalisant quadratiquement un trop grand éloignement vis-à-vis du point de départ v.

Toute la difficulté est ici que ce n'est pas le champ de vitesse u qui est en jeu mais la norme 1 de son gradient. C'est ici que l'algorithme de Chambolle [1] entre en jeu .

5.4 Lien théorique entre l'algorithme de Chambolle et l'opérateur proximal

Pour un champ de vitesses intermédiaire g et un paramètre de pénalisation $\lambda > 0$, ce calcul équivaut par définition à la résolution du problème d'optimisation suivant :

$$\text{prox}_{\lambda TV}(g) = \arg\min_{u} \left(\frac{1}{2\lambda}\|u - g\|_2^2 + \int_\Omega |\nabla u| \, dx \right) \tag{17}$$

5.4.1 Dualité de Fenchel-Legendre

La résolution directe de ce problème (dans l'espace primal) se heurte à la non-différentiabilité de la norme L^1 en zéro. Pour contourner cette singularité, l'approche standard en analyse convexe non lisse consiste à exploiter la dualité de Fenchel-Legendre.

Celle-ci permet de reformuler la Variation Totale à l'aide d'une variable duale $\mathbf{p}$ (un champ de vecteurs), sous une contrainte stricte de norme :

$$\int_\Omega |\nabla u| \, dx = \max_{|\mathbf{p}| \leq 1} \int_\Omega u \, \text{div}(\mathbf{p}) \, dx \tag{18}$$

Cette réécriture permet de transférer la non-linéarité géométrique de la fonction objectif vers une contrainte sur l'espace de recherche dual (la boule unité $|\mathbf{p}| \leq 1$).

5.4.2 La décomposition de Moreau et le problème dual

Plutôt que de calculer l'opérateur proximal directement, il est mathématiquement équivalent de le déduire à partir de son problème dual. Ce principe fondamental est régi par l'identité de Moreau. Dans le cadre de la Variation Totale, cette identité établit une relation analytique directe entre la solution primale u (l'image débruitée) et la solution duale optimale $\mathbf{p}^*$:

$$u = g + \lambda \operatorname{div}(\mathbf{p}^*) \tag{19}$$

En injectant cette relation dans le problème de minimisation initial, la recherche de l'opérateur proximal se réduit à la recherche de ce champ de vecteurs dual optimal $\mathbf{p}^*$. Après simplification des termes croisés, le problème dual se formule comme la minimisation d'une énergie strictement quadratique et continûment différentiable :

$$\mathbf{p}^* = \arg\min_{|\mathbf{p}|\leq 1} \|\lambda \operatorname{div}(\mathbf{p}) + g\|_2^2 \tag{20}$$

Reste à réaliser une descente de gradient sous contrainte pour déterminer $\mathbf{p}^*$.

L'algorithme de Chambolle [1] est un schéma numérique itératif qui exploite ce développement pour calculer l'opérateur proximal. On s'en servira ainsi dans l'implémenation.

5.5 Mise en oeuvre algorithmique

On implémente une nouvelle méthode ForwardBackwardTVL2 à la classe Optimization, afin d'appliquer la méthode de Chambolle. On utilisera la méthode denoise_tv_chambolle de la bibliothèque skimage.restoration dont le pseudo-code est donné en 1.

La résolution de ce problème necessite tout de même de découpler le comportement en norme L1 et celui en norme L2.

Contrairement au modèle de Horn-Schunck purement lisse, le modèle TV-L2 est un compromis : une régularisation par Variation Totale (norme L^1) pour préserver les discontinuités du mouvement, couplée à une attache aux données quadratique (norme L^2).

Puisque le terme d'attache aux données est convexe et différentiable, cette énergie peut être minimisée de manière itérative par un schéma d'optimisation de type *Forward-Backward* (ou descente de gradient proximale). L'algorithme alterne entre deux étapes à chaque itération n :

1. Étape *Forward* (Attache aux données) :
On effectue un pas de descente de gradient explicite, de taille d'apprentissage τ, le long de la dérivée du terme d'attache aux données. Cela produit un champ de vitesses intermédiaire $\mathbf{w}_{temp} = (u_{temp}, v_{temp})^T$ qui respecte l'équation du flot optique :

$$u_{temp} = u^n - \tau\lambda I_x(I_x u^n + I_y v^n + I_t) \tag{21}$$
$$v_{temp} = v^n - \tau\lambda I_y(I_x u^n + I_y v^n + I_t) \tag{22}$$

2. Étape *Backward* (Régularisation) :
Ce champ de vitesses intermédiaire est ensuite projeté via l'opérateur proximal associé à la Variation Totale, afin d'imposer un lissage par morceaux. Mathématiquement, cela revient à évaluer :

$$u^{n+1} = \operatorname{prox}_{\tau TV}(u_{temp}) \tag{23}$$
$$v^{n+1} = \operatorname{prox}_{\tau TV}(v_{temp}) \tag{24}$$

Algorithm 1 Algorithme de projection duale de Chambolle

Require:

g : Champ de vitesses intermédiaire (bruité)
λ : Paramètre de régularisation (force du lissage)
τ : Pas temporel de mise à jour (condition de stabilité : $\tau \leq 1/8$)
N_{max} : Nombre maximum d'itérations
ϵ : Tolérance pour le critère d'arrêt

Ensure:

u : Champ de vitesses régularisé par Variation Totale

Initialisation du champ dual (vecteur) : $\mathbf{p}^{(0)} \leftarrow \mathbf{0}$
$n \leftarrow 0$
while $n < N_{max}$ **do**
▷ 1. Calcul de l'écart à l'image via la divergence
    $A^{(n)} \leftarrow \text{div}(\mathbf{p}^{(n)}) - \frac{g}{\lambda}$
▷ 2. Évaluation de la force de mise à jour locale
    $\mathbf{d}^{(n)} \leftarrow \nabla A^{(n)}$
▷ 3. Mise à jour et projection stricte sur la boule unité (Clipping)
    $\mathbf{p}^{(n+1)} \leftarrow \frac{\mathbf{p}^{(n)} + \tau \mathbf{d}^{(n)}}{1 + \tau |\mathbf{d}^{(n)}|}$
▷ 4. Vérification du critère de convergence
    if $\|\mathbf{p}^{(n+1)} - \mathbf{p}^{(n)}\|_\infty < \epsilon$ **then**
        break
    end if
    $n \leftarrow n + 1$
end while
$u \leftarrow g - \lambda \, \text{div}(\mathbf{p}^{(n)})$
return u

6 Résultats

6.1 Comparaison entre les deux méthodes d'optimisation en norme L2

Afin de comparer les deux méthodes, on réalise un benchmark qui vise à mesurer le temps d'optimisation pour une vidéo étalon donnée. Dans un souci de représentativitée, on réalisera l'optimisation sur l'ensemble de la vidéo. Cette dernière a par ailleurs été réduite en qualité (réduite à 360p) afin de réduire le temps de calcul (C'est une considération à discuter). La vidéo montre un mouvement de corps rigide noir, sur fond blanc, translaté à vitesse constante. On choisit un learning rate lr variant dans la liste suivante : [1e2, 1e0, 1e-2] et une tolérance de 5e-4.

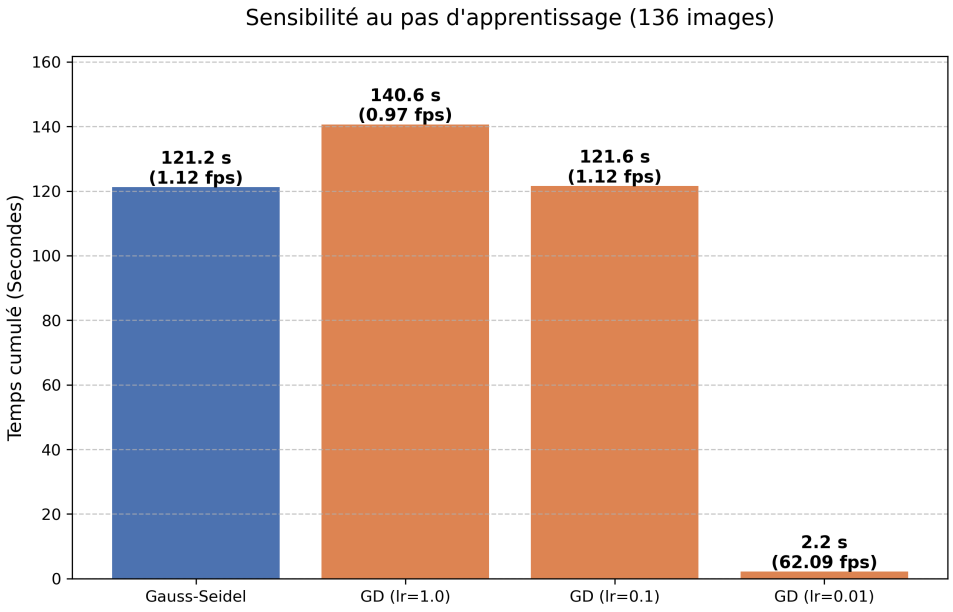


FIGURE 1 – Comparaison des temps de convergence entre la méthode de Gauss-Seidel et la descente de gradient pour la résolution de l'équation du flot optique.

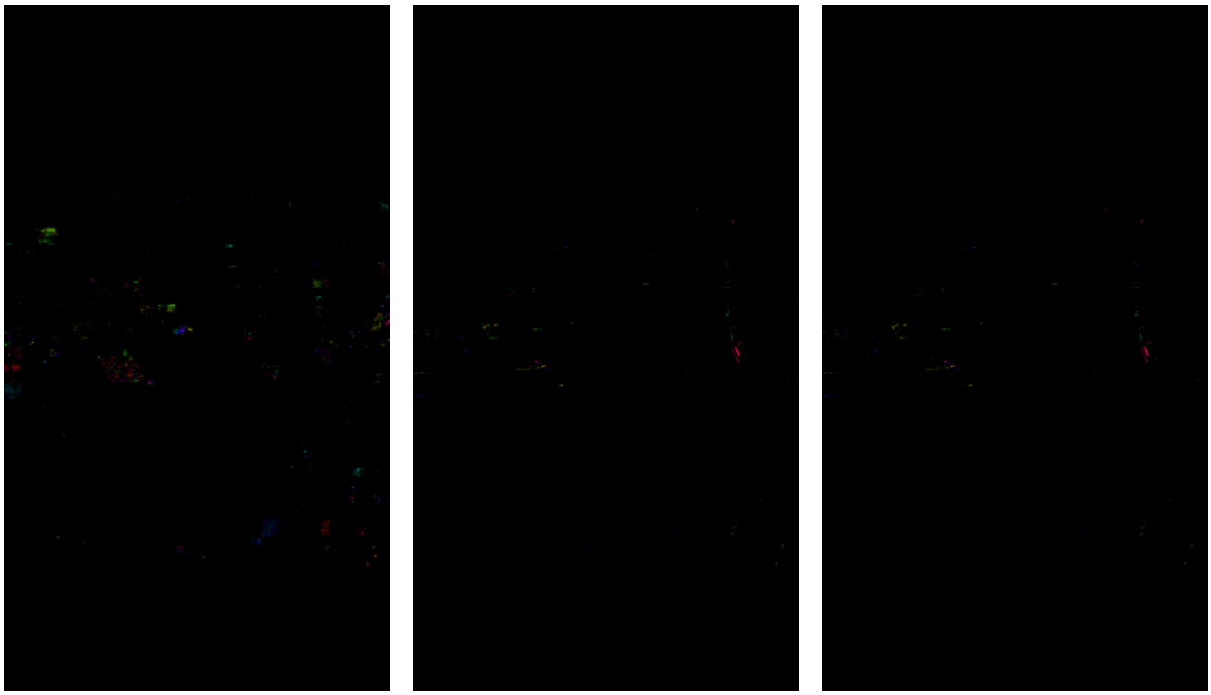
La figure 1 montre les résultats. Premièrement, pour une valeur de pas trop petite (lr = 0.01), on observe que l'algorithme converge instantanément car la différence entre deux pas est trop faible. Pour lr = 0.1, les performances sont très proches de la méthode de Gauss-Seidel. Et pour lr = 1, la méthode de la descente de gradient est légérement plus lente. Dans la mesure où la méthode de descente à pas fixe nécessite de devoir régler un hyperparamètre supplémentaire, on favorisera la méthode de Gauss-Seidel.

On choisira donc tout la méthode de Gauss-Seidel pour le reste des simulations.

6.2 Influence du paramètre de lissage

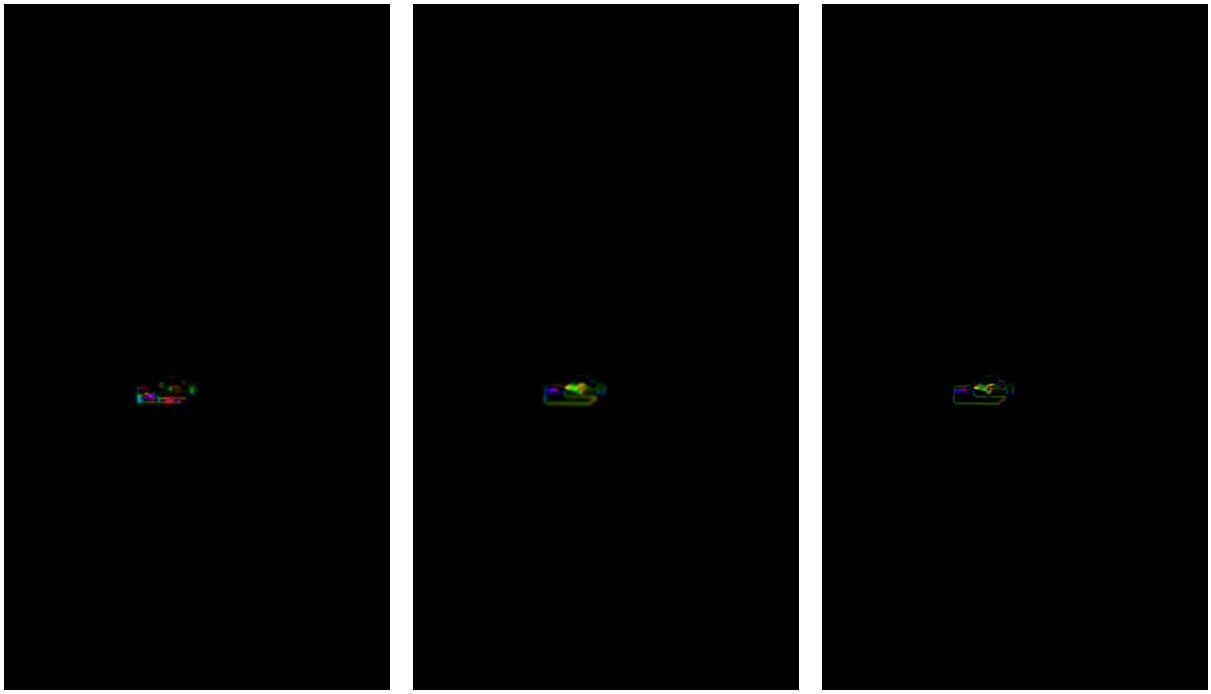
On cherche dans cette sous-partie à illustrer l'influence de l'hyper-paramètre α dans le cadre du modèle de Horn-Schunck (régularisation L^2). Pour ce faire, on réalise des simulations pour les valeurs suivantes : 0.01, 1.0 et 100.0. La vidéo choisie montre, en caméra fixe, le passage de plusieurs Formules 1 sur le très célèbre circuit de Spa-Francorchamps, dans le virage du Raidillon. Cette séquence a été sélectionnée pour évaluer la robustesse de la méthode face à des objets se mouvant à une vitesse importante sur un fond statique.

Sur les figures 2 et 3, on compare les champs de vitesses obtenus pour les différentes valeurs de α.



(a) $\alpha = 0.01$ (b) $\alpha = 1.0$ (c) $\alpha = 100.0$

FIGURE 2 – Influence du paramètre de régularisation α au début de la séquence (Frame 37). Illustration de la sensibilité au bruit sur un fond quasi-statique.



(a) $\alpha = 0.01$ (b) $\alpha = 1.0$ (c) $\alpha = 100.0$

FIGURE 3 – Influence du paramètre de régularisation α lors du passage de la monoplace (Frame 53). Pour $\alpha = 100$, l'écrasement quadratique ne laisse survivre que les forts gradients (contours).

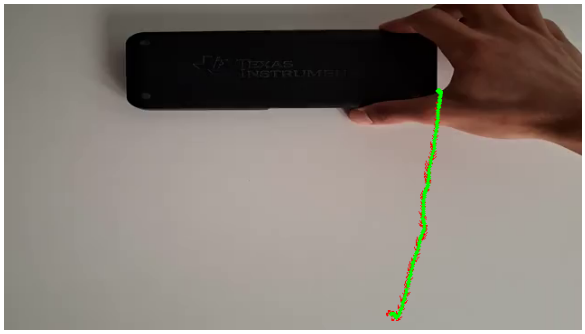
La première série d'images (Figure 2) illustre parfaitement le comportement de l'algorithme sur des zones quasi-statiques : on observe clairement qu'un paramètre de lissage trop faible ($\alpha = 0.01$) rend la méthode extrêmement sensible au bruit d'acquisition. Le terme d'attache aux données étant prépondérant, la moindre variation lumineuse locale parasite est interprétée comme un mouvement.

Lorsque la Formule 1 traverse le champ de vision (Figure 3), le rôle de α révèle le comportement mathématique singulier de la régularisation quadratique (L^2). De prime abord, l'image générée avec $\alpha = 100$ semble offrir la définition la plus nette de la monoplace. Cependant, on constate que seule la "silhouette" (les contours extérieurs) est capturée, tandis que l'intérieur de la carrosserie est vide (vitesse nulle). Ce phénomène s'explique par la nature de la pénalisation L^2 : à très fort α, l'algorithme force le champ de vitesses à s'homogénéiser avec la zone largement majoritaire de l'image, c'est-à-dire le fond statique de vitesse nulle. Les seules zones capables de résister à cet "écrasement" vers zéro sont les arêtes fortement contrastées de la voiture, où les gradients spatiaux (I_x, I_y) sont gigantesques, rendant l'attache aux données localement invincible.

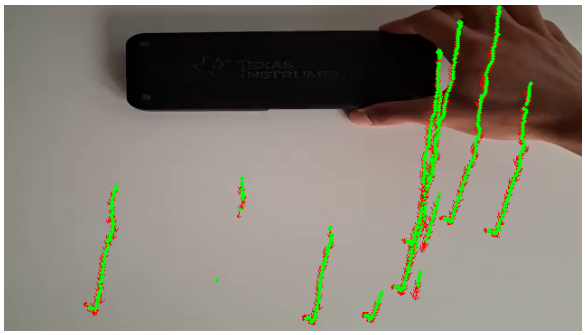
La valeur intermédiaire ($\alpha = 1.0$) offre donc le compromis physique le plus cohérent : elle dissipe efficacement le bruit de fond du bitume tout en autorisant le maintien d'une vitesse non nulle au cœur des zones texturées de la carrosserie. L'objet est ainsi perçu comme une masse pleine en mouvement, et non comme un simple contour filaire.

6.3 Analyse de la méthode de Lucas-Kanade

Pour évaluer cette méthode, nous appliquons l'algorithme aux deux séquences vidéo précédemment introduites. Les trajectoires des points d'intérêt suivis sont superposées sur la première image de chaque vidéo pour en visualiser le déplacement global.



(a) Paramètres par défaut

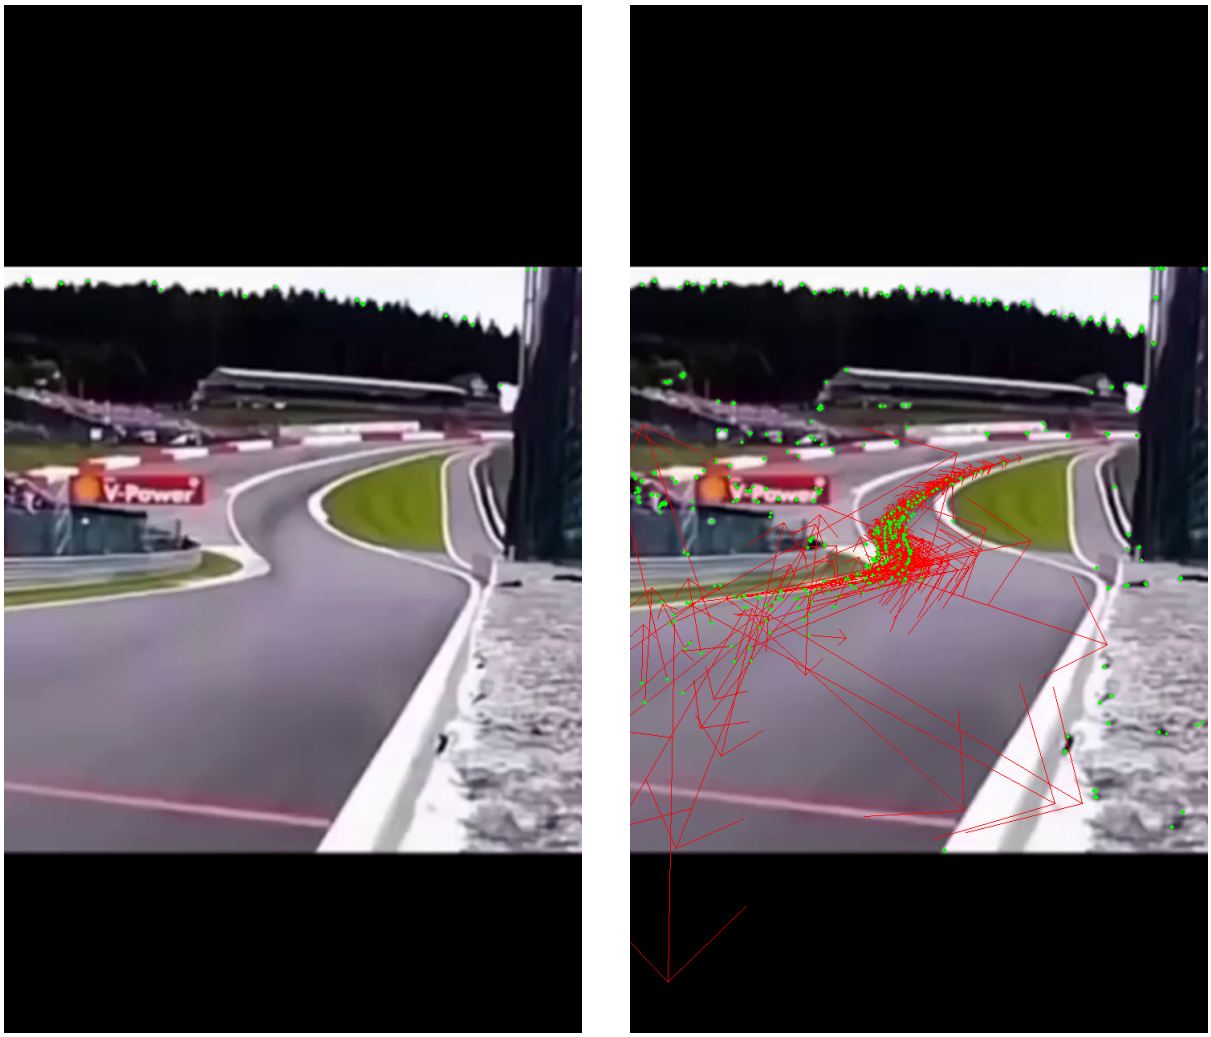


(b) Paramètres optimisés, recalcule des points d'intérêt dans la boucle

FIGURE 4 – Comparaison de l'extraction des caractéristiques sur le mouvement de corps rigide

Dans le cas du mouvement de corps rigide, avec les paramètres par défaut, la détection de coins ne s'accroche qu'à un nombre très restreint de points. Néanmoins, le suivi de ces caractéristiques reste cohérent vis-à-vis de la trajectoire réelle du solide.

Cependant, l'application naïve de l'algorithme sur la séquence de Formule 1 met en lumière plusieurs limites critiques. D'une part, l'initialisation statique ne permet pas de suivre les monoplaces, car celles-ci n'entrent dans le champ de vision qu'après les premières secondes de la vidéo. D'autre part, même en forçant une détection continue, l'algorithme a tendance à s'accrocher exclusivement aux éléments les plus contrastés du décor statique (comme la cime des arbres en arrière-plan), ignorant les véhicules en mouvement. Cette vulnérabilité, directement liée à la qualité de la détection initiale des points d'intérêt, pénalise l'ensemble de la méthode.



(a) Implémentation initiale

(b) Re-détection dynamique

FIGURE 5 – Impact de l'optimisation de la méthode sur la séquence dynamique de Formule 1

Malgré ces obstacles, l'algorithme de Lucas-Kanade présente l'avantage majeur d'être beaucoup moins coûteux en ressources que celui de Horn et Schunck (le temps de traitement de la séquence F1 chutant de plusieurs minutes à quelques secondes). Cette performance s'explique par la nature éparse de la méthode, qui ne calcule le vecteur vitesse que sur une fraction infime des pixels de l'image.

Afin de tirer parti de cette rapidité tout en obtenant un suivi robuste, il a été nécessaire de remanier le pipeline algorithmique. L'intégration d'une boucle de re-détection dynamique conditionnelle permet désormais d'accrocher les nouveaux véhicules entrant dans le champ. En parallèle, l'ajustement fin des hyperparamètres de détection (notamment l'abaissement du seuil de qualité `qualityLevel` pour tolérer la carrosserie des voitures et l'augmentation de la distance minimale `minDistance` pour forcer une répartition spatiale des points) a permis de détourner l'attention de l'algorithme du décor de fond, aboutissant à un suivi des monoplaces rapide et cohérent.

La figure 5 montre une amélioration notable dans la détection des monoplaces. Néanmoins, un grand nombre de points sont détectés sans qu'il ne soit vraiment d'intêret. Cela induit une perte de temps de calcul car l'algorithme recalcule le mouvement de tous les points. De plus, lors de l'entrée des monoplaces dans l'image, les vecteurs ne sont pas orientés dans le bon sens, ce qui traduit une faible précision.

La figure 4 montre quant à elle que les points détectés ne sont pas nécessairement ceux auxquelles l'on peut s'attendre. Avec, un objet plus anguleux, peut-être que l'algorithme aurait mieux saisit les dimensions de l'objet.

6.4 Analyse des résultats pour la méthode TV-L2 et comparaison avec la régularisation L2

On se propose de comparer, trame par trame, les différences géométriques et cinématiques entre le modèle de régularisation TV-L1 et le modèle TV-L2. Pour garantir une comparaison rigoureuse, les hyper-paramètres sont fixés à des valeurs identiques pour les deux méthodes, avec $\alpha = 1.0$ et un critère d'arrêt de convergence établi à $tol = 5 * 10^{-4}$.

Afin de mettre en exergue les spécificités de chaque norme d'attache aux données, nous comparerons selon deux axes :

— **La gestion des occlusions et des frontières de mouvement**

— **La dynamique de convergence**

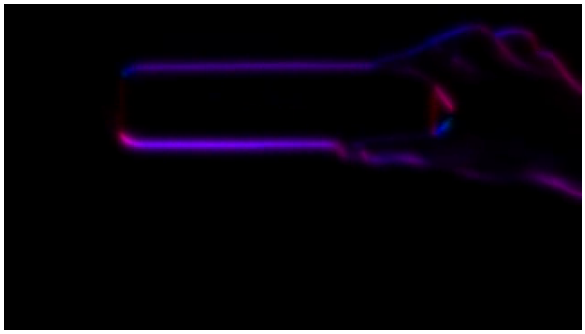
Pour illustrer ces propos, les champs de vitesses (représentation colorimétrique HSV et champs de vecteurs) ont été extraits à des instants clés de la séquence (trames 10, 50 et 120), reproduisant la méthodologie visuelle de la section précédente.

6.4.1 Comparaison visuelle : Horn-Schunck vs TV-L2

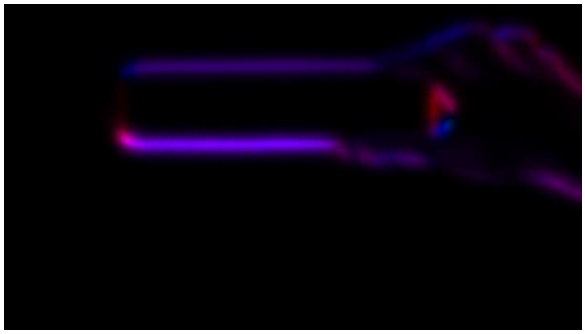
Afin de confronter les propriétés géométriques des deux modèles (diffusion quadratique contre préservation des contours), une extraction comparative a été réalisée sur une même trame de la séquence.

Il est cependant crucial de soulever un biais méthodologique quant au réglage de l'hyper-paramètre de régularisation α. Comme le montre la Figure 6, avec une valeur nominale identique ($\alpha = 1.0$), les deux champs de vitesses apparaissent visuellement très similaires : ils se limitent à la détection des contours lumineux de l'objet en mouvement, sans parvenir à densifier sa surface interne.

Cette similitude n'est pas le fruit d'une équivalence des modèles mathématiques, mais d'une différence d'échelle dans l'implémentation des énergies. Dans le schéma *Forward-Backward* du



(a) Horn-Schunck (Gauss-Seidel) : $\alpha = 1.0$



(b) TV-L2 (Chambolle) : $\alpha = 1.0$

FIGURE 6 – Comparaison des champs de vitesses à α nominal identique (Frame 40). Les deux modèles se limitent ici à la détection des contours spatiaux fortement contrastés, illustrant le biais d'échelle de l'hyper-paramètre dans l'implémentation TV-L2.

modèle TV-L2, le poids effectif de la régularisation appliqué par l'opérateur proximal de Chambolle est proportionnel au pas d'apprentissage de la descente de gradient (souvent noté τ ou lr). Par conséquent, un $\alpha = 1.0$ couplé à un pas d'apprentissage faible (par exemple $lr = 0.01$) rend le terme de Variation Totale quasi-inopérant (régularisation effective de 0.01). Le modèle se comporte alors comme une simple minimisation de l'attache aux données, ne détectant le mouvement que sur les forts gradients spatiaux.

Pour observer la véritable dichotomie structurelle entre la diffusion isotrope de Horn-Schunck et la segmentation par morceaux de la Variation Totale, il convient donc de ne pas comparer les algorithmes à α nominal constant, mais à leur point de fonctionnement optimal respectif, compensant ainsi ce facteur d'échelle.

6.4.2 Analyse des performances temporelles

Afin d'évaluer la viabilité de ces méthodes dans un contexte de traitement vidéo, un profilage temporel a été réalisé sur la séquence complète. Le temps de calcul moyen par trame a été mesuré pour les deux approches étudiées, à paramètres de lissage comparables ($\alpha = 1.0$) et avec un critère d'arrêt commun ($tol = 10^{-4}$ ou un maximum de 100 itérations).

Comme l'illustre la Figure 7, le résultat est à première vue contre-intuitif : l'optimisation par Variation Totale (TV-L2), bien que mathématiquement plus complexe (schéma *Forward-Backward* impliquant des boucles imbriquées), s'exécute en moyenne plus de trois fois plus rapidement (0.16 s/trame) que l'algorithme de Gauss-Seidel lié au modèle de Horn-Schunck (0.55 s/trame).

Ce décalage s'explique par deux biais structurels inhérents à notre implémentation qu'il convient de souligner :

— **Le taux de convergence et la propagation spatiale :** Le solveur de Gauss-Seidel propage l'information cinématique localement (pixel par pixel via le Laplacien discret). Sur des zones homogènes larges telles que la carrosserie, la diffusion de la vitesse est extrêmement lente, forçant fréquemment l'algorithme à saturer la limite stricte des 100 itérations sans satisfaire le critère de tolérance. À l'inverse, l'opérateur proximal de Chambolle favorise des sauts constants par morceaux, permettant une convergence globale plus rapide.

— **L'optimisation logicielle :** Le solveur de Gauss-Seidel a été codé nativement en Python via la bibliothèque *NumPy*. Bien que les opérations matricielles soient vectorisées, la boucle itérative principale subit le surcoût temporel d'exécution de l'interpréteur. L'opérateur de Chambolle repose quant à lui sur la fonction `denoise_tv_chambolle` issue de

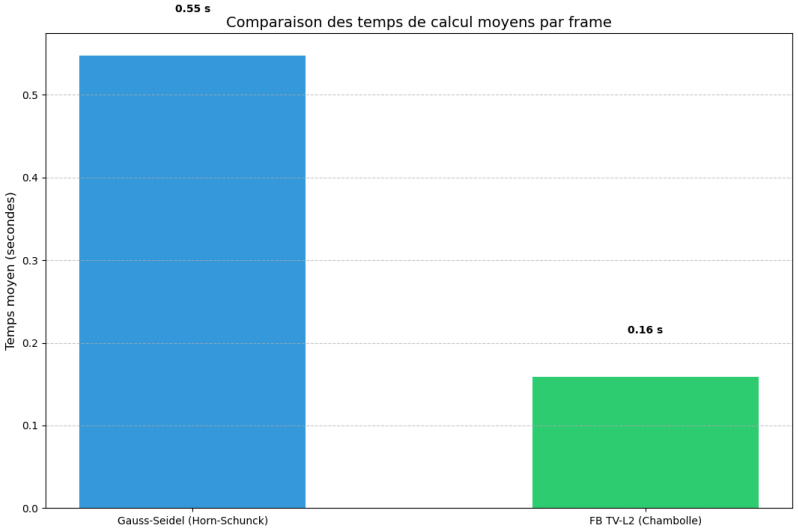


FIGURE 7 – Comparaison des temps de calcul moyens par trame entre la méthode de Horn-Schunck (résolue par Gauss-Seidel) et le modèle TV-L2 (opérateur de Chambolle).

la librairie *scikit-image*, dont le cœur algorithmique est pré-compilé en C, offrant des performances d'exécution inatteignables en Python pur.

Ainsi, bien que la méthode de Horn-Schunck soit théoriquement moins coûteuse par itération, la lenteur de sa propagation spatiale couplée aux différences d'architecture logicielle confère un avantage applicatif incontestable au modèle TV-L2 au sein de notre environnement d'étude.

7 Conclusion

Au terme de cette étude comparative portant sur l'estimation du flot optique, la confrontation entre le modèle de Horn-Schunck (régularisation quadratique L^2) et l'approche par Variation Totale (TV-L2) a permis de mettre en évidence des comportements mathématiques et algorithmiques fondamentalement distincts.

D'une part, la méthode de Horn-Schunck illustre parfaitement les limites de la diffusion isotrope : bien qu'elle parvienne à densifier le champ de vitesses dans les zones homogènes via son effet de remplissage, elle peine à préserver les discontinuités franches, entraînant un lissage spatial excessif au-delà des contours réels de l'objet en mouvement. De plus, sa résolution locale par l'algorithme de Gauss-Seidel souffre d'une propagation spatiale particulièrement lente.

D'autre part, la régularisation par Variation Totale a démontré sa supériorité structurelle pour l'analyse cinématique de corps rigides, telle qu'une monoplace de Formule 1. Grâce à l'opérateur proximal de Chambolle, le modèle TV-L2 parvient à segmenter le mouvement en zones constantes par morceaux, offrant des contours nets et une géométrie parfaitement détourée, tout en filtrant efficacement le bruit de fond statique de la piste.

Enfin, cette analyse a souligné l'importance cruciale de l'ingénierie algorithmique dans l'application de tels modèles. Outre la nécessité de compenser les biais d'échelle lors de l'étalonnage des hyper-paramètres de lissage (α), notre profilage temporel a prouvé que la complexité théorique du schéma *Forward-Backward* est largement compensée en pratique. Sa convergence globale rapide, couplée à une implémentation logicielle optimisée, le rend nettement plus compétitif.

En définitive, bien que plus exigeant dans son implémentation initiale, le modèle TV-L2 s'impose comme une solution robuste, géométriquement précise et performante, particulièrement adaptée aux défis de la vision par ordinateur moderne et à l'analyse d'objets à forte dynamique.

Références

[1] Antonin Chambolle. An algorithm for total variation minimization and applications. *Journal of Mathematical Imaging and Vision*, 20(1-2) :89–97, 2004.

[2] Berthold K.P. Horn and Brian G. Schunck. Determining optical flow. *Artificial intelligence*, 17(1-3) :185–203, 1981.

[3] Bruce D. Lucas and Takeo Kanade. An iterative image registration technique with an application to stereo vision. In *Proceedings of the 7th international joint conference on Artificial intelligence (IJCAI)*, volume 2, pages 674–679, 1981.