

Projet Optical Flow – UM4MA266

Optimisation et science des données

UGWONALI Nathan
Master 1 Mathématiques et Applications

Année 2025–2026

Résumé

Ce rapport présente les grands principes, le processus d'implémentation ainsi que les résultats de l'étude de quelques algorithmes liés à l'optical flow.

Table des matières

1 Introduction **1**

2 Modélisation mathématique **1**
2.1 Equation de conservation 1
2.2 Condition de lissage 2
2.3 Minimisation 2

3 Implémentation numérique **2**
3.1 Approximations 2
3.2 Implémentation orientée objet 3
3.3 Méthodes d'optimisation 3
3.3.1 Méthode de Gauss-Seidel 3
3.3.2 Méthode de descente de gradient à pas fixe 4

4 Résultats **4**
4.1 Comparaison entre les deux méthodes 4
4.2 Influence du paramètre de lissage 5

5 Perpectives **8**

1 Introduction

L'optical flow se définit comme la mesure du mouvement relatif entre deux images. Ce concept est particulièrement bien adapté à la vidéo dans la mesure où ces dernières se décomposent en plusieurs images successives (30 à 60 images par secondes en général). Ainsi, en supposant que chaque frame est relativement proche de la précédente, on peut approximer le champ des vitesses associé au mouvement décrit par les images. On trouvera de nombreuses application dans le domaine de la vision par ordinateur.

2 Modélisation mathématique

2.1 Equation de conservation

On se place dans le formalisme d'Euler. On considère l'éclairement en un pixel situé au coordonnées (x, y) et à l'instant t, noté $E(x, y, t)$. L'hypothèse central est la conservation de cet eclairement au cours du temps. Ceci ce traduit par l'équation de conservation :

$$\frac{DE}{Dt} = 0 \tag{1}$$

Ceci devient en développant :

$$\frac{\partial E}{\partial x}\frac{dx}{dt} + \frac{\partial E}{\partial y}\frac{dy}{dt} + \frac{\partial E}{\partial t} = 0 \tag{2}$$

En notant $E_i = \frac{\partial E}{\partial i}, i \in \{x, y, t\}$ et $u = \frac{dx}{dt}, v = \frac{dy}{dt}$, on obtient la forme compact suivante :

$$E_x u + E_y v + E_t = 0 \tag{3}$$

L'objectif est alors de trouver u et v, sachant (E_x, E_y, E_t) donné par la vidéo considérée.

2.2 Condition de lissage

Le problème posé tel que précédement est mal posé puisqu'il existe une infité de couple (u, v) verifiant l'équation de conservation. Il s'agit alors de considérer une nouvelle équation afin de compléter le problème. Une approche est donnée par Horn et Schunck [1] qui proposent de considérer une condition de lissage traduisant le fait que le champ des vitesses en un point est globalement similaire a ses voisins. On introduit alors l'erreur de lissage, que l'on va venir chercher à minimiser :

$$e_s = \|\nabla u\|^2 + \|\nabla v\|^2 = \left(\frac{\partial u}{\partial x}\right)^2 + \left(\frac{\partial u}{\partial y}\right)^2 + \left(\frac{\partial v}{\partial x}\right)^2 + \left(\frac{\partial v}{\partial y}\right)^2 \tag{4}$$

On obtient alors, en intégrant sur tous le domaine Ω, l'intégrale suivante, que l'on cherche à minimiser en (u, v) :

$$\mathcal{E}(u, v) = \iint_\Omega \left((E_x u + E_y v + E_t)^2 + \alpha^2 \left(\left(\frac{\partial u}{\partial x}\right)^2 + \left(\frac{\partial u}{\partial y}\right)^2 + \left(\frac{\partial v}{\partial x}\right)^2 + \left(\frac{\partial v}{\partial y}\right)^2 \right) \right) dxdy \tag{5}$$

Avec α un hyperparamètre qui arbitre entre effets globaux de lissage et effets locaux de variation de l'intensité lumineuse.

2.3 Minimisation

Afin de minimiser une intégrale, on trouvera en les équations d'Euler-Lagrange un outil puissant. Nous admettront bien volontier que ces dernières nous mènent au système d'équation suivant :

$$\begin{cases} E_x(E_x u + E_y v + E_t) - \alpha^2 \Delta u = 0 \\ E_y(E_x u + E_y v + E_t) - \alpha^2 \Delta v = 0 \end{cases} \tag{6}$$

Un tel système d'équation n'est pas solvable sans approximation intelligentes. C'est pourquoi on se propose de résoudre ce dernier par une méthode itérative telle que celles de Jacobi ou Gauss-Seidel. Pour ce faire, on commence par approximer le laplacien $\Delta f = \bar{f} - f$, ce qui donne :

$$\begin{cases} E_x(E_x u + E_y v + E_t) - \alpha^2 (\bar{u} - u) = 0 \\ E_y(E_x u + E_y v + E_t) - \alpha^2 (\bar{v} - v) = 0 \end{cases} \tag{7}$$

On réarrange les termes :

$$\begin{cases} u - \bar{u} = -E_x \frac{E_x u + E_y v + E_t}{\alpha^2} \\ v - \bar{v} = -E_y \frac{E_x u + E_y v + E_t}{\alpha^2} \end{cases} \tag{8}$$

3 Implémentation numérique

3.1 Approximations

Il s'agit dans un premier temps de récupérer le flux vidéo. L'idée étant de gérer les images deux-à-deux afin d'en extraire les variations d'intensité lumineuse par convolution. Toujours

selon Horn et Schunck [1], une méthode consiste à approximer les variations pixels par pixels et frame par frame étant donné que l'on a pas d'idée a priori du facteur d'échelle ni des fps de la vidéo.

$$\begin{cases} E_x \approx \frac{1}{4}\Big[(E_{i,j+1,k} - E_{i,j,k}) + (E_{i+1,j+1,k} - E_{i+1,j,k}) \\ \qquad + (E_{i,j+1,k+1} - E_{i,j,k+1}) + (E_{i+1,j+1,k+1} - E_{i+1,j,k+1})\Big] \\ E_y \approx \frac{1}{4}\Big[(E_{i+1,j,k} - E_{i,j,k}) + (E_{i+1,j+1,k} - E_{i,j+1,k}) \\ \qquad + (E_{i+1,j,k+1} - E_{i,j,k+1}) + (E_{i+1,j+1,k+1} - E_{i,j+1,k+1})\Big] \\ E_t \approx \frac{1}{4}\Big[(E_{i,j,k+1} - E_{i,j,k}) + (E_{i+1,j,k+1} - E_{i+1,j,k}) \\ \qquad + (E_{i,j+1,k+1} - E_{i,j+1,k}) + (E_{i+1,j+1,k+1} - E_{i+1,j+1,k})\Big] \end{cases} \tag{9}$$

3.2 Implémentation orientée objet

Ainsi, on implémente une première classe VideoDataHandler qui permet d'une part d'extraire le flux d'images issu d'une vidéo donnée en donnant les images par paquets de deux. Cette dernière permet aussi de faire du prétraitement de l'image, à savoir la passer en monochrome et avec intensité normalisée à 1. A cela, on ajoute les classes GradIntensity et Velocity qui permettent le calcul respectivement, des champs liés à l'intensité pour une paire d'images fournies par le VideoHandler et des champs liés à la vitesse, notamment le Laplacien. Enfin, la classe Optimization est introduite pour encoder les différentes méthodes d'optimisations envisagées.

3.3 Méthodes d'optimisation

3.3.1 Méthode de Gauss-Seidel

Il s'agit ici de la méthode que Horn et Schunck [1] ont choisi d'implémenter de par son efficacité dans ce contexte. Le principe de la méthode est le suivant : face à un système d'équations linéaires vaste et creux (comme c'est le cas pour les pixels d'une image), les méthodes de résolution directe par inversion de matrice sont beaucoup trop coûteuses en temps de calcul et en mémoire. La méthode de Gauss-Seidel propose une approche itérative. À partir d'une estimation initiale du champ de vitesses (généralement nulle), l'algorithme met à jour la valeur de chaque variable en utilisant les valeurs les plus récentes de ses voisines, jusqu'à atteindre un état d'équilibre.

Dans notre cas, nous cherchons à résoudre le système algébrique obtenu après discrétisation des équations d'Euler-Lagrange :

$$\begin{cases} (\alpha^2 + E_x^2)u + E_x E_y v = \alpha^2 \bar{u} - E_x E_t \\ E_x E_y u + (\alpha^2 + E_y^2)v = \alpha^2 \bar{v} - E_y E_t \end{cases} \tag{10}$$

Plutôt que de traiter ce système de manière globale, Horn et Schunck ont réécrit ces équations pour exprimer la vitesse d'un pixel en fonction des dérivées spatio-temporelles locales de l'image (E_x, E_y, E_t) et de la moyenne des vitesses de son voisinage spatio-temporel ($\bar{u}$, $\bar{v}$).

En isolant astucieusement le terme fractionnaire commun aux deux équations, on obtient le schéma itératif suivant. Soit k l'indice de l'itération courante, les nouvelles composantes du vecteur vitesse pour l'itération $k+1$ sont données par :

$$\begin{cases} u^{k+1} = \bar{u}^k - E_x \dfrac{E_x \bar{u}^k + E_y \bar{v}^k + E_t}{\alpha^2 + E_x^2 + E_y^2} \\ \\ v^{k+1} = \bar{v}^k - E_y \dfrac{E_x \bar{u}^k + E_y \bar{v}^k + E_t}{\alpha^2 + E_x^2 + E_y^2} \end{cases} \tag{11}$$

Cette formulation est particulièrement élégante car elle évite toute inversion matricielle. Chaque itération affine le champ de vitesses en propageant l'information des zones riches en gradients (les contours) vers les zones homogènes, grâce au calcul des moyennes locales $\bar{u}$ et $\bar{v}$ qui agissent comme un terme de diffusion.

Le processus itératif est répété jusqu'à ce que le système converge. En pratique, la condition d'arrêt est définie par un seuil de tolérance ϵ. L'algorithme s'interrompt lorsque la différence quadratique moyenne entre le champ de vitesses de l'itération k et celui de l'itération $k+1$ devient strictement inférieure à ce seuil, ou lorsqu'un nombre maximum d'itérations est atteint.

3.3.2 Méthode de descente de gradient à pas fixe

Afin d'établir un point de comparaison algorithmique avec l'approche de Horn et Schunck, le système a également été résolu en utilisant une méthode d'optimisation universelle du premier ordre : la descente de gradient à pas fixe.

On ne rappelera pas le principe très connue de la méthode.

Soit λ le pas d'apprentissage (ou *learning rate*), fixé empiriquement et maintenu constant tout au long de l'optimisation. La règle de mise à jour simultanée des champs de vitesses à l'itération $k+1$ est donnée par :

$$\begin{cases} u^{k+1} = u^k - \lambda \nabla_u E(u^k, v^k) \\ v^{k+1} = v^k - \lambda \nabla_v E(u^k, v^k) \end{cases} \tag{12}$$

Contrairement à la méthode de Gauss-Seidel qui exploite la structure mathématique spécifique du Laplacien pour garantir une convergence stable, la descente de gradient classique est extrêmement sensible au choix de l'hyperparamètre λ.

Si le pas λ est choisi trop grand, l'algorithme oscille et finit par diverger, ce qui se traduit par une explosion des valeurs des vecteurs vitesses. S'il est choisi trop petit, la descente vers le minimum global est assurée, mais le nombre d'itérations requis pour atteindre le seuil de tolérance ϵ devient prohibitif, rendant cette méthode considérablement plus lente que l'approche proposée initialement par Horn et Schunck.

4 Résultats

4.1 Comparaison entre les deux méthodes

Afin de comparer les deux méthodes, on réalise un benchmark qui vise à mesurer le temps d'optimisation pour une vidéo étalon donnée. Dans un souci de représentativitée, on réalisera l'optimisation sur l'ensemble de la vidéo. Cette dernière a par ailleurs été réduite en qualité (réduite à 360p) afin de réduire le temps de calcul (C'est une considération à discuter). La vidéo montre un mouvement de corps rigide noir, sur fond blanc, translaté à vitesse constante. On choisit un learning rate lr variant dans la liste suivante : [1e2, 1e0, 1e-2] et une tolérance de 1e-4.

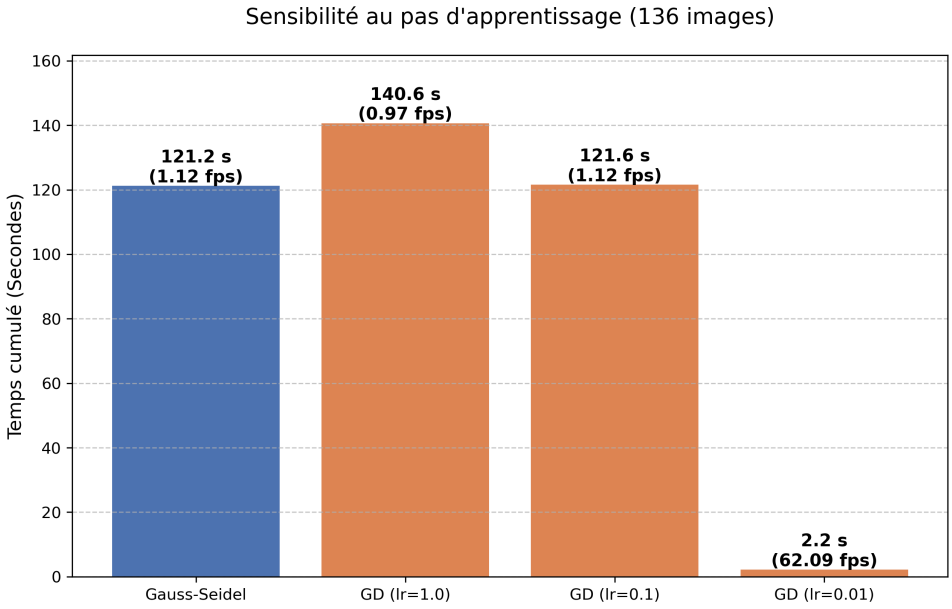


FIGURE 1 – Comparaison des temps de convergence entre la méthode de Gauss-Seidel et la descente de gradient pour la résolution de l'équation du flot optique.

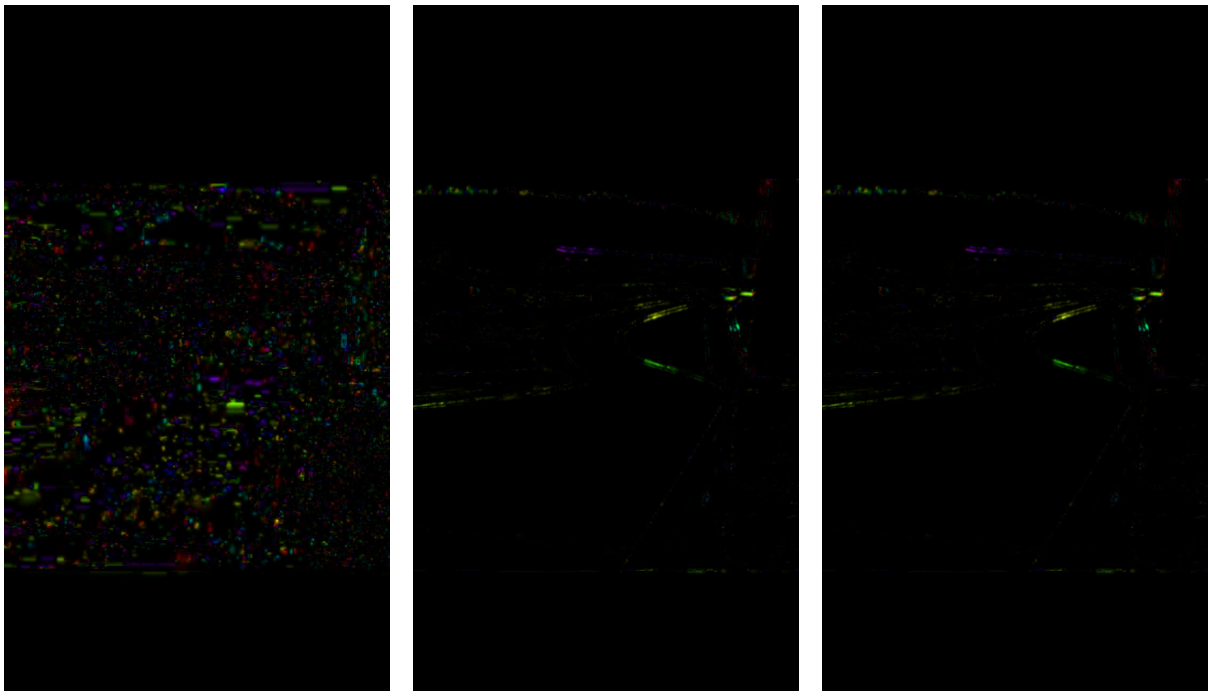
La figure 1 montre les résultats. Premièrement, pour une valeur de pas trop petite (lr = 0.01), on observe que l'algorithme converge instantanément car la différence entre deux pas est trop faible. Pour lr = 0.1, les performances sont très proches de la méthode de Gauss-Seidel. Et pour lr = 1, la méthode de la descente de gradient est légérement plus lente. Dans la mesure où la méthode de descente à pas fixe nécessite de devoir régler un hyperparamètre supplémentaire, on favorisera la méthode de Gauss-Seidel.

On choisira donc tout la méthode de Gauss-Seidel pour le reste des simulations.

4.2 Influence du paramètre de lissage

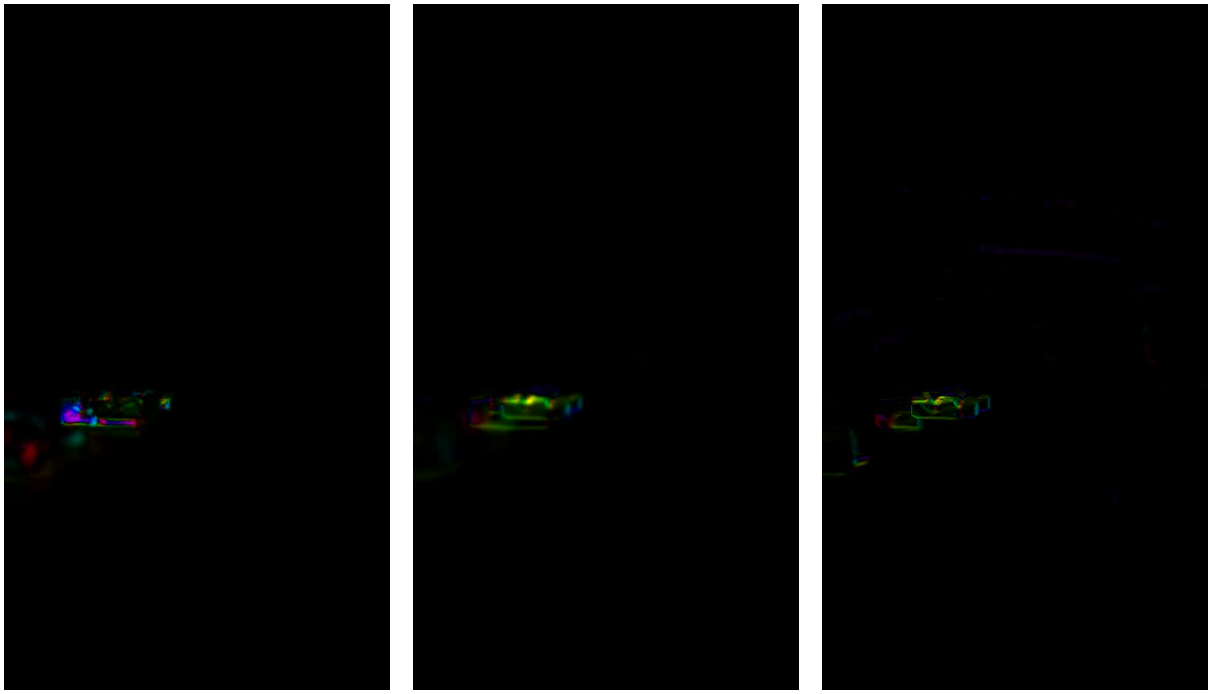
On cherche dans cette sous-partie à illustrer l'influence de l'hyper-paramètre α. Pour ce faire, on réalise des simulations pour des valeurs les valeurs suivantes [1e2, 1e0, 1e-2]. La vidéo choisie montre, en caméra fixe, le passage de plusieurs Formules 1 sur le très célébre circuit de Spa-Francorchamps, dans le virage du Raidillon. Cette vidéo a été choisie pour illustrer la robustesse de la méthode avec des objets se mouvant à une vitesse importante et de taille changeante (due à la perspective, les monoplaces s'éloignant).

Sur les figures 2, 3, 4, on montre les frames 10, 50 et 120 pour les valeurs de α mentionnées. On observe clairement les effets d'un alpha trop faible en figures 2 et 4, avec une capture du bruit trop forte lorsque l'image est "statique". Il en est de même lorsque la Formule 1 s'éloigne dans la vidéo, et la capture de son mouvement est perdue dans la bruit. Lorsque $\alpha = 100$, on observe en figures 3 que la monoplace est détecté avec une grande définition dans les détails, là ou pour $\alpha = 1$, la monoplace est légerement plus flou, ce qui correspond mieux à ce que l'on attend dans la mesure ou l'on souhaite observer une masse de couleur uniforme se déplacer le long du virage. En figure 4 et pour $\alpha = 1$ et $\alpha = 100$ on observe enfin que les monoplaces laissent une trace, plus ou moins épaisse, laissant à penser que l'algorithme induit une forme de diffusion avant un retour à zéro du champ de vitesse. Le terme de lagrangien étant un terme induisant un champ de vitesse relativement lisse, cela empêche des dégradés de vitesse trop important et créer ces traces.



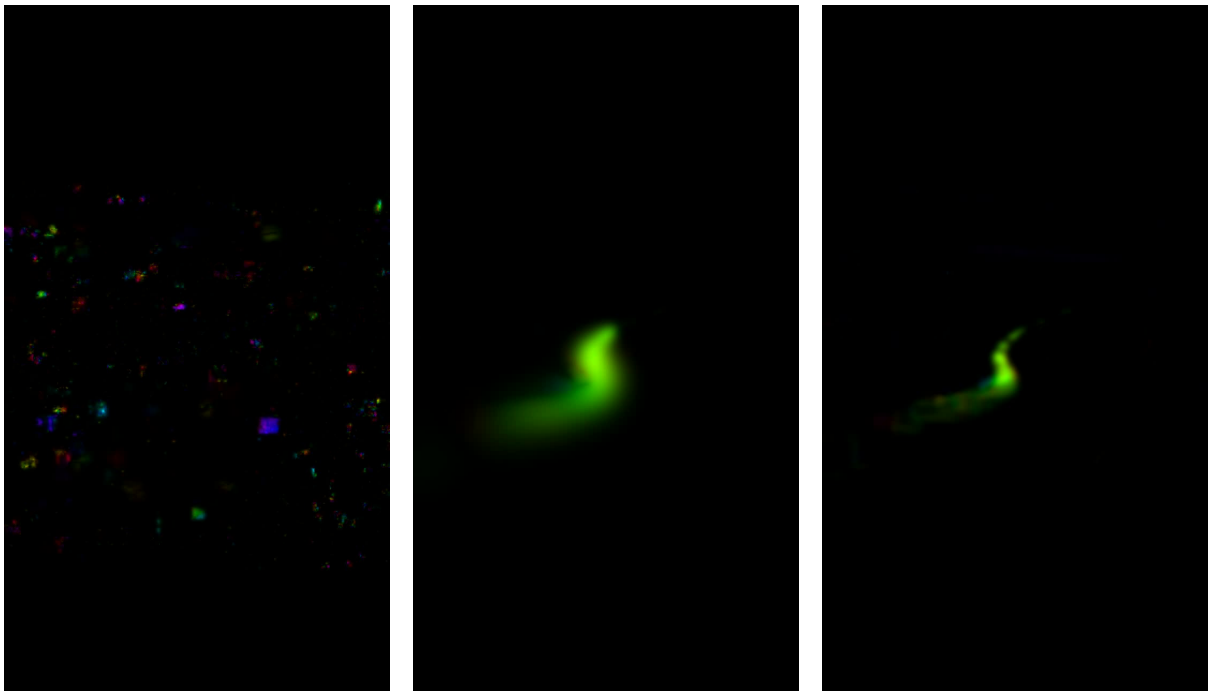
(a) $\alpha = 0.01$ (b) $\alpha = 1.0$ (c) $\alpha = 100.0$

FIGURE 2 – Influence du paramètre de régularisation α au début de la séquence (Frame 10).



(a) $\alpha = 0.01$ (b) $\alpha = 1.0$ (c) $\alpha = 100.0$

FIGURE 3 – Influence du paramètre de régularisation α sur l'estimation du flot optique (méthode de Horn-Schunck), (Frame 50).



(a) $\alpha = 0.01$ (b) $\alpha = 1.0$ (c) $\alpha = 100.0$

FIGURE 4 – Influence du paramètre de régularisation α à la fin de la séquence (Frame 120). À gauche, un α faible induit une méthode très sensible au bruit. Au centre, un compromis permettant d'obtenir un champ de vitesses cohérent mais avec l'apparition d'une "queue" de vitesse. À droite, un α encore admissible, mais le lissage commence à se faire ressentir.

En conclusion, il apparait assez nettement qu'un choix emprique du paramètre de lissage α est nécessaire. Un lissage trop fort noiera l'information dans le champ de vitesse ambiant et créera des dégradés de vitesse nuisibles, tandis qu'un lissage trop faible capturera essentiellement les bruits de la vidéo, en particulier lorsque la vidéo reste "statique".

5 Perpectives

Une première piste de travail serait d'implémenter la méthode de Lucas-Kanade [2], et de la comparer à celle de Horn et Shunck.

Dans un second temps, mettre en place l'approche par pyramides d'images serait intéressant pour combler les problèmes en grand déplacement, que l'on aura préalablement mise en exergue.

Enfin,on pourra regarder ce qui se passe lorsque l'on passe d'une pénalisation en norme 2 à une pénalisation en norme 1 afin de régler le problème de diffusion de la vitesse.

Références

[1] Berthold K.P. Horn and Brian G. Schunck. Determining optical flow. *Artificial intelligence*, 17(1-3) :185–203, 1981.

[2] Bruce D. Lucas and Takeo Kanade. An iterative image registration technique with an application to stereo vision. In *Proceedings of the 7th international joint conference on Artificial intelligence (IJCAI)*, volume 2, pages 674–679, 1981.